Η Στήλη της Ροζέτας του Ανθρώπινου Κεφαλαίου

Στην εργασία αυτή θα επεξεργαστείτε τη μελέτη A Rosetta Stone of Human Capital (https://www.cgdev.org/publication/rosetta-stone-human-capital), του Dev Patel και Justin Sandefur.

Όπως ίσως γνωρίζετε, υπάρχουν διάφορων τύπων τεστ που μετράνε τις επιδόσεις των μαθητών στην ανάγνωση, γραφή, και μαθηματικά, μεταξύ χωρών. Το πρόβλημα είναι ότι δεν χρησιμοποιούν όλες οι χώρες τα ίδια τεστ. Οι συγγραφείς της μελέτης βρήκαν έναν τρόπο να μετατρέπονται τα αποτελέσματα των διαφορετικών τεστ μεταξύ χωρών. Έτσι δημιούργησαν αυτό που αποκαλούν «Στήλη της Ροζέτας του Ανθρώπινου Κεφαλαίου», επειδή μας επιτρέπει να μεταφράζουμε το ανθρώπινο κεφάλαιο, όπως αυτό εκφράζεται μέσω των αποτελεσμάτων του εκπαιδευτικού συστήματος, μεταξύ χωρών.

Πάνος Λουρίδας, Αναπληρωτής Καθηγητής
Τμήμα Διοικητικής Επιστήμης και Τεχνολογίας
Οικονομικό Πανεπιστήμιο Αθηνών
louridas@aueb.gr

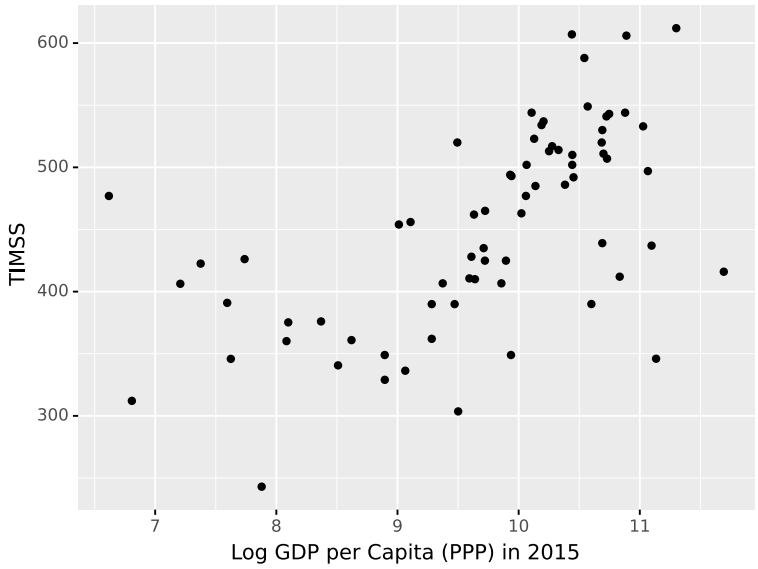
Ερωτήσεις

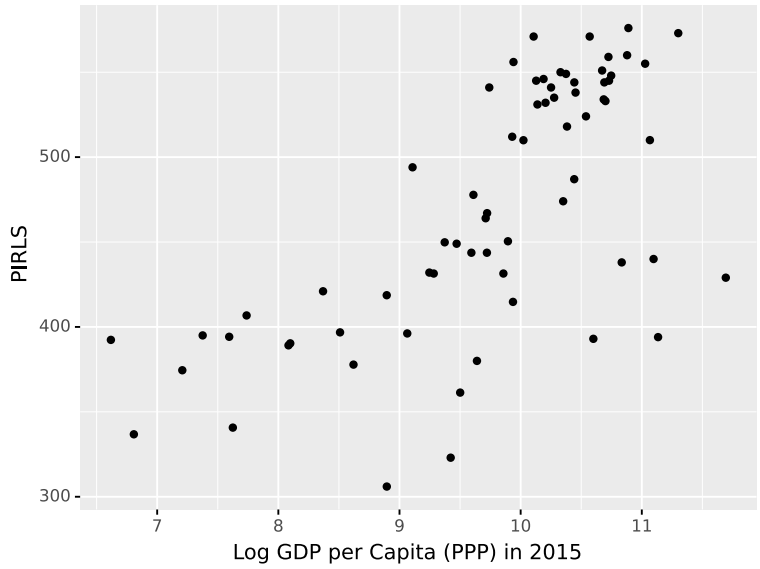
Τα αποτελέσματα της μελέτης είναι διαθέσιμα στο https://www.cgdev.org/sites/default/files/patel-sandefur-human-capital-final-results.xlsx (https://www.cgdev.org/sites/default/files/patel-sandefur-human-capital-final-results.xlsx). Θα κατεβάσετε το αρχείο και θα βάλετε το φύλλο εργασίας `Country Scores` σε ένα `DataFrame` το οποίο εμείς θα ονομάσουμε `country_scores` . Η απόδοση των μαθητών μεταξύ των χωρών αποτιμάται με τις μετρικές `Median Math Score (TIMSS Scale, 4th Grade)` , μαθηματικά στην 4η τάξη, και `Median Reading Score (PIRLS Scale, 4th Grade)` , ανάγνωση στην 4η τάξη.

E1: Εισόδημα και Αποτελέσματα των Τεστ

Θα διερευνήσετε τη σχέση μεταξύ του εισοδήματος σε κάθε χώρα και των αποτελεσμάτων των τεστ TIMSS και PIRLS, όπως στο 4.1 και την εικόνα 5 της μελέτης. Συγκεκριμένα, θα διερευνήσετε μέσω παλινδρόμησης τη σχέση μεταξύ του λογαρίθμου του εισοδήματος και του σκορ TIMMS, και του λογαρίθμου του εισοδήματος και του σκορ PIRLS. Αφού φτιάξετε τα σχετικά μοντέλα και σχολιάσετε τα αποτελέσματά σας, θα πρέπει να παράξετε διαγράμματα των δεδομένων αντίστοιχα με τα παρακάτω.

Για την απάντηση στην ερώτηση θα χρειαστείτε και το αρχείο `WDI_data.csv` , το οποίο περιέχει δεδομένα εισοδήματος ανά χώρα από την Παγκόσμια Τράπεζα.





Λήψη και επεξεργασία δεδομένων

Κατεβάζω το αρχείο `patel-sandefur-human-capital-final-results.xlsx` από τον σύνδεσμο και το αποθηκεύω στον φάκελο *assignment2*. Για την ανάγνωσή του από την pandas, χρειάζεται επίσης η βιβλιοθήκη `openpyxl`.

In [1]:
```
!pip install openpyxl
```

```
Requirement already satisfied: openpyxl in c:\users\kyriakos\appdata\local\programs\python\python39\lib\site-packages (3.0.9)
Requirement already satisfied: et-xmlfile in c:\users\kyriakos\appdata\local\programs\python\python39\lib\site-packages (from openpyxl) (1.1.0)

WARNING: You are using pip version 21.1.3; however, version 22.0.4 is available.
You should consider upgrading via the 'c:\users\kyriakos\appdata\local\programs\python\python39\python.exe -m pip install --upgrade pip' command.
```

In [2]:
```
import pandas as pd

country_scores = pd.read_excel("./patel-sandefur-human-capital-final-results.xlsx", sheet_name = "Country Scores")
```

In [3]:
```
country_scores.head()
```

Out[3]:

	Country	Country Code	Percent Above Math Benchmark (400 on TIMSS Scale)	Percent Above Reading Benchmark (400 on PIRLS Scale)	Median Math Score (TIMSS Scale, 4th Grade)	Median Reading Score (PIRLS Scale, 4th Grade)
0	U.A.E.	ARE	64.000000	63.982311	437.000000	440.000000
1	Argentina	ARG	51.000000	66.000000	406.652557	431.443542
2	Armenia	ARM	71.505402	NaN	454.000000	NaN
3	Australia	AUS	90.000000	92.932800	520.000000	534.000000
4	Austria	AUT	95.302193	97.104111	511.000000	533.000000

Κατασκευάζω ένα αντίγραφο για κάθε μετρική, διατηρώντας μόνον τις χρήσιμες στήλες, και στην συνέχεια αφαιρώ τις απουσιάζουσες τιμές από κάθε ένα ξεχωριστά.

In [4]:
```
country_scores_timss = country_scores[["Country", "Country Code", "Median Math Score (TIMSS Scale, 4th Grade)"]].copy()
country_scores_pirls = country_scores[["Country", "Country Code", "Median Reading Score (PIRLS Scale, 4th Grade)"]].copy()
```

In [5]:
```
country_scores_timss.dropna(axis = 0, inplace = True) ## axis 0 for rows
country_scores_pirls.dropna(axis = 0, inplace = True)
```

In [6]:
```
country_scores_timss.head()
```

Out[6]:

	Country	Country Code	Median Math Score (TIMSS Scale, 4th Grade)
0	U.A.E.	ARE	437.000000
1	Argentina	ARG	406.652557
2	Armenia	ARM	454.000000
3	Australia	AUS	520.000000
4	Austria	AUT	511.000000

In [7]:
```
country_scores_pirls.head()
```

Out[7]:

	Country	Country Code	Median Reading Score (PIRLS Scale, 4th Grade)
0	U.A.E.	ARE	440.000000
1	Argentina	ARG	431.443542
3	Australia	AUS	534.000000
4	Austria	AUT	533.000000
5	Azerbaijan	AZE	467.000000

Οι απουσιάζουσες τιμές της στήλης που με ενδιαφέρει στο αρχείο *WDI_data.csv* έχουν αντικατασταθεί με δύο τελείες.

In [8]:
```
gdp = pd.read_csv("./WDI_data.csv", dtype = {"2015 [YR2015]": float}, na_values = [".."])
```

In [9]:
```
gdp.head()
```

Out[9]:

	Country Name	Country Code	Series Name	Series Code	2015 [YR2015]
0	Afghanistan	AFG	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	1809.016488
1	Afghanistan	AFG	School enrollment, primary (% net)	SE.PRM.NENR	NaN
2	Afghanistan	AFG	School enrollment, primary (% gross)	SE.PRM.ENRR	107.225357
3	Albania	ALB	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	10971.292517
4	Albania	ALB	School enrollment, primary (% net)	SE.PRM.NENR	95.199600

Διατηρώ μόνο τις σειρές που αφορούν GDP per capita (κατά κεφαλήν ΑΕΠ) και το στοιχείο τους στην αντίστοιχη στήλη δεν είναι κενό.

In [10]:
```
gdp.dropna(axis = 0, inplace = True) ## axis 0 for rows
gdp.drop(gdp[~gdp["Series Name"].str.contains("GDP")].index, inplace = True)
```

In [11]:
```
gdp.head()
```

Out[11]:

	Country Name	Country Code	Series Name	Series Code	2015 [YR2015]
0	Afghanistan	AFG	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	1809.016488
3	Albania	ALB	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	10971.292517
6	Algeria	DZA	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	13724.723853
15	Angola	AGO	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	6231.067992
18	Antigua and Barbuda	ATG	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	20154.947488

Για κάθε μετρική κατασκευάζω με συνένωση ένα dataframe που περιέχει και την πληροφορία του ΑΕΠ.

In [12]:
```
timss_and_gdp = gdp.merge(country_scores_timss, on = ["Country Code"])
```

In [13]:
```
timss_and_gdp.head()
```

Out[13]:

	Country Name	Country Code	Series Name	Series Code	2015 [YR2015]	Country	Median Math Score (TIMSS Scale, 4th Grade)
0	Argentina	ARG	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	19101.297392	Argentina	406.652557
1	Armenia	ARM	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	8195.933650	Armenia	454.000000
2	Australia	AUS	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	43719.502165	Australia	520.000000
3	Austria	AUT	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	44353.875214	Austria	511.000000
4	Azerbaijan	AZE	GDP per capita, PPP (constant 2011 internation...	NY.GDP.PCAP.PP.KD	16698.863653	Azerbaijan	465.000000

Αφαιρώ περιττές στήλες.

In [14]:
```
timss_and_gdp.drop(axis = 1, columns = ["Series Name", "Series Code", "Country"], inplace = True)
```

In [15]:
```
timss_and_gdp.head()
```

Out[15]:

	Country Name	Country Code	2015 [YR2015]	Median Math Score (TIMSS Scale, 4th Grade)
0	Argentina	ARG	19101.297392	406.652557
1	Armenia	ARM	8195.933650	454.000000
2	Australia	AUS	43719.502165	520.000000
3	Austria	AUT	44353.875214	511.000000
4	Azerbaijan	AZE	16698.863653	465.000000

Ομοίως και για το PIRLS.

In [16]:
```
pirls_and_gdp = gdp.merge(country_scores_pirls, on = ["Country Code"])
pirls_and_gdp.drop(axis = 1, columns = ["Series Name", "Series Code", "Country"], inplace = True)
pirls_and_gdp.head()
```

Out[16]:

	Country Name	Country Code	2015 [YR2015]	Median Reading Score (PIRLS Scale, 4th Grade)
0	Argentina	ARG	19101.297392	431.443542
1	Australia	AUS	43719.502165	534.000000
2	Austria	AUT	44353.875214	533.000000
3	Azerbaijan	AZE	16698.863653	467.000000
4	Benin	BEN	1987.167146	394.196686

Λογάριθμοι στήλης ΑΕΠ.

In [17]:
```
import numpy as np
pirls_and_gdp["2015 [YR2015]"] = pirls_and_gdp["2015 [YR2015]"].map(lambda x: np.log(x))
```

In [18]:
```
pirls_and_gdp.head()
```

Out[18]:

	Country Name	Country Code	2015 [YR2015]	Median Reading Score (PIRLS Scale, 4th Grade)
0	Argentina	ARG	9.857512	431.443542
1	Australia	AUS	10.685550	534.000000
2	Austria	AUT	10.699955	533.000000
3	Azerbaijan	AZE	9.723096	467.000000
4	Benin	BEN	7.594465	394.196686

In [19]:
```
timss_and_gdp["2015 [YR2015]"] = timss_and_gdp["2015 [YR2015]"].map(lambda x: np.log(x))
timss_and_gdp.head()
```

Out[19]:

	Country Name	Country Code	2015 [YR2015]	Median Math Score (TIMSS Scale, 4th Grade)
0	Argentina	ARG	9.857512	406.652557
1	Armenia	ARM	9.011393	454.000000
2	Australia	AUS	10.685550	520.000000
3	Austria	AUT	10.699955	511.000000
4	Azerbaijan	AZE	9.723096	465.000000

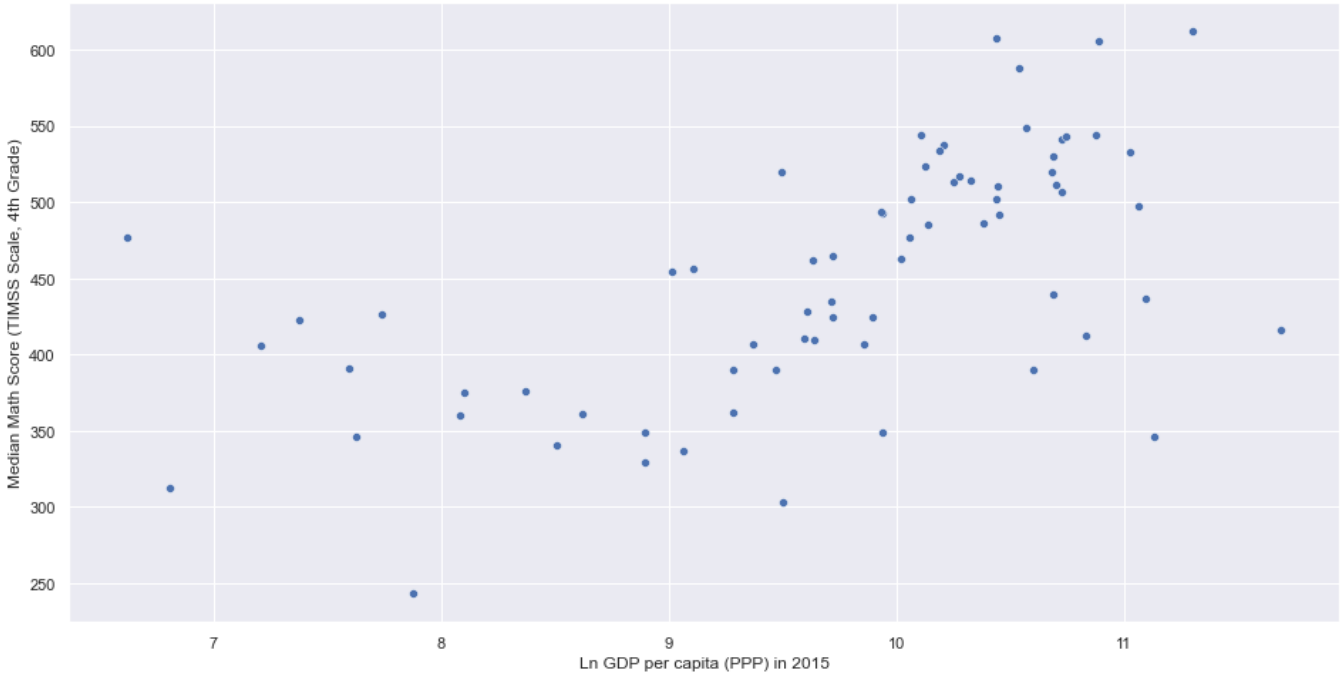
Απεικόνιση

In [20]:
```
import seaborn as sns

sns.set_style(style = "darkgrid")
sns.set(rc = {"figure.figsize": (16, 8)})

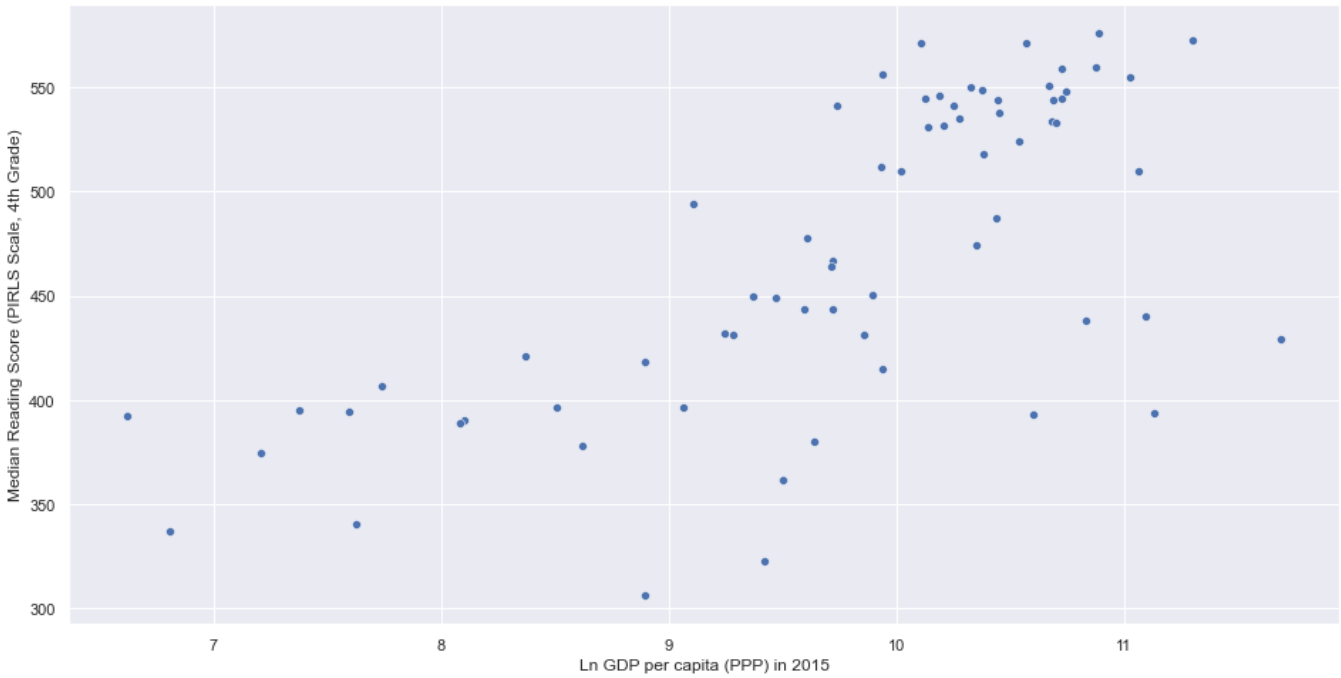
ax = sns.scatterplot(data = timss_and_gdp, x = "2015 [YR2015]", y = "Median Math Score (TIMSS Scale, 4th Grade)")
ax.set(xlabel = "Ln GDP per capita (PPP) in 2015")
```

Out[20]:
```
[Text(0.5, 0, 'Ln GDP per capita (PPP) in 2015')]
```



In [21]:
```
ax = sns.scatterplot(data = pirls_and_gdp, x = "2015 [YR2015]", y = "Median Reading Score (PIRLS Scale, 4th Grade)")
ax.set(xlabel = "Ln GDP per capita (PPP) in 2015")
```

Out[21]:
```
[Text(0.5, 0, 'Ln GDP per capita (PPP) in 2015')]
```



Χρωματισμός ανά ήπειρο

Ομαδοποιώ με χρώμα τα σημεία ανά ήπειρο. Για να αυτοματοποιηθεί η διαδικασία αντιστοίχισης κάθε χώρας σε ήπειρο χρησιμοποιώ τις κάτωθι βιβλιοθήκες.

In [75]:
```
!pip install pycountry
```

...

In [76]:
```
!pip install pycountry-convert
```

...

In [22]:
```
## https://stackoverflow.com/a/55910166
import pycountry_convert as pc

def get_continent_by_country_code(x):
    return pc.country_alpha2_to_continent_code(pc.country_alpha3_to_country_alpha2(x))
```

In [23]:
```
timss_and_gdp = timss_and_gdp.assign(continent = timss_and_gdp["Country Code"].map(get_continent_by_country_code))
```

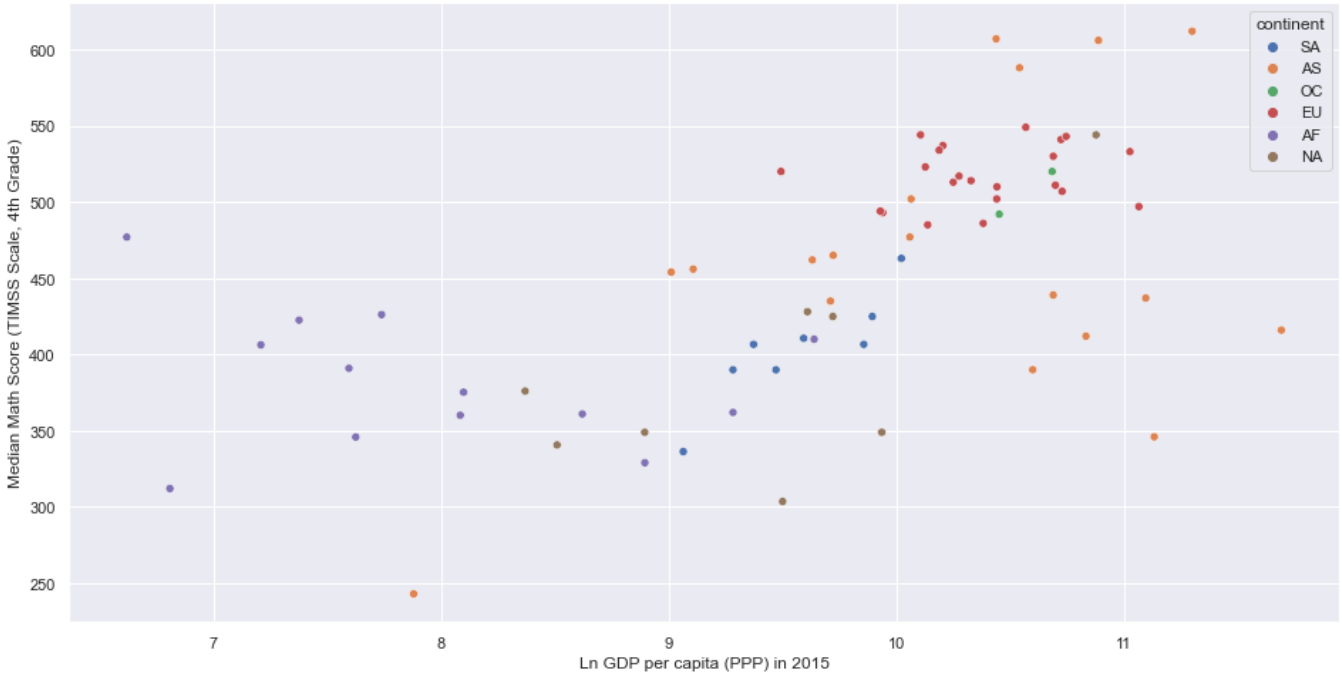
In [24]:
```
timss_and_gdp.head()
```

Out[24]:

	Country Name	Country Code	2015 [YR2015]	Median Math Score (TIMSS Scale, 4th Grade)	continent
0	Argentina	ARG	9.857512	406.652557	SA
1	Armenia	ARM	9.011393	454.000000	AS
2	Australia	AUS	10.685550	520.000000	OC
3	Austria	AUT	10.699955	511.000000	EU
4	Azerbaijan	AZE	9.723096	465.000000	AS

In [25]:
```
ax = sns.scatterplot(data = timss_and_gdp, x = "2015 [YR2015]", y = "Median Math Score (TIMSS Scale, 4th Grade)", hue = "continen
ax.set(xlabel = "Ln GDP per capita (PPP) in 2015")
```

Out[25]:
```
[Text(0.5, 0, 'Ln GDP per capita (PPP) in 2015')]
```



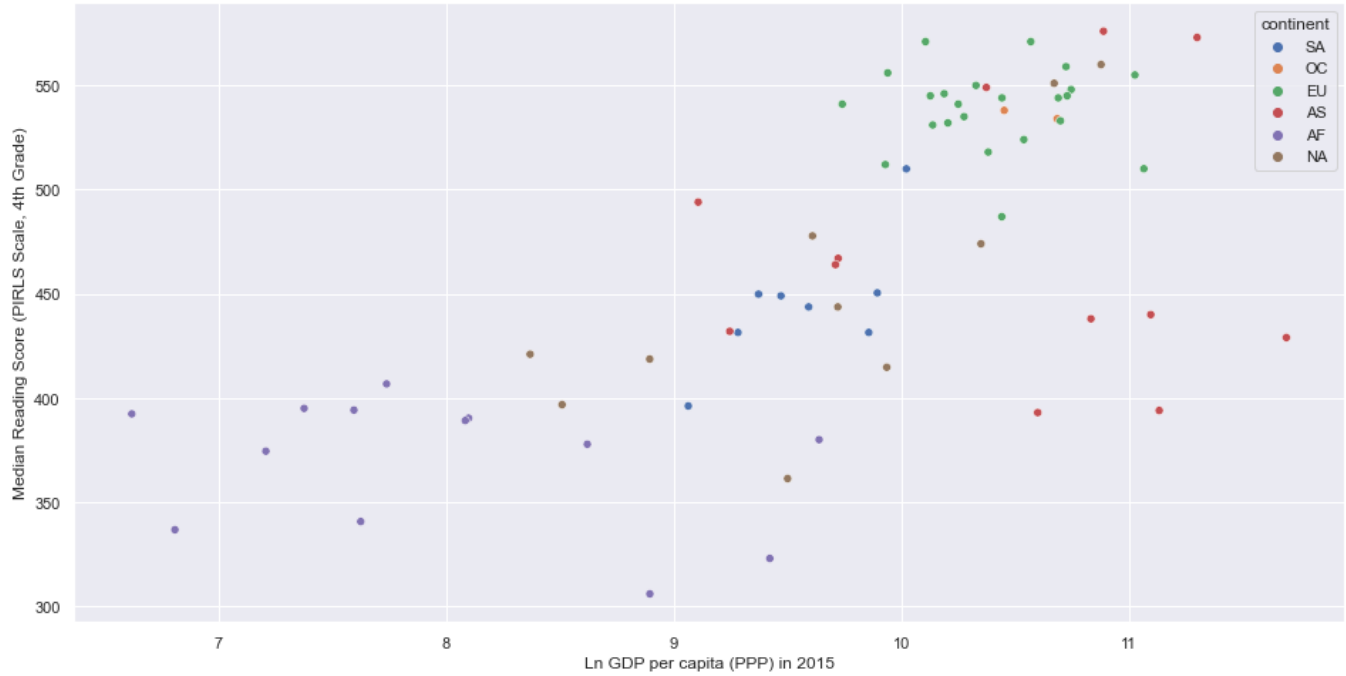
In [26]:
```
pirls_and_gdp = pirls_and_gdp.assign(continent = pirls_and_gdp["Country Code"].map(get_continent_by_country_code))
pirls_and_gdp.head()
```

Out[26]:

	Country Name	Country Code	2015 [YR2015]	Median Reading Score (PIRLS Scale, 4th Grade)	continent
0	Argentina	ARG	9.857512	431.443542	SA
1	Australia	AUS	10.685550	534.000000	OC
2	Austria	AUT	10.699955	533.000000	EU
3	Azerbaijan	AZE	9.723096	467.000000	AS
4	Benin	BEN	7.594465	394.196686	AF

In [27]:
```
ax = sns.scatterplot(data = pirls_and_gdp, x = "2015 [YR2015]", y = "Median Reading Score (PIRLS Scale, 4th Grade)", hue = "conti
ax.set(xlabel = "Ln GDP per capita (PPP) in 2015")
```

Out[27]:
```
[Text(0.5, 0, 'Ln GDP per capita (PPP) in 2015')]
```



Και στα δύο διαγράμματα οι χώρες του πρώτου κόσμου βρίσκονται σε καλύτερη θέση, πάνω δεξιά κυρίως ευρωπαϊκές (και ασιατικές βέβαια), και κάτω αριστερά κυρίως αφρικανικές και αμερικανικές.

Συσχέτιση

Σύντομη επισκόπηση των συντελεστών συσχέτισης

In [28]:
```
from scipy.stats import stats

stats.pearsonr(timss_and_gdp["2015 [YR2015]"], timss_and_gdp["Median Math Score (TIMSS Scale, 4th Grade)"])
```

Out[28]:
```
(0.592986063663243, 5.07092364820821e-08)
```

In [29]:
```
stats.pearsonr(pirls_and_gdp["2015 [YR2015]"], pirls_and_gdp["Median Reading Score (PIRLS Scale, 4th Grade)"])
```

Out[29]:
```
(0.6762226118838529, 2.4787369620437173e-10)
```

In [30]:
```
stats.spearmanr(timss_and_gdp["2015 [YR2015]"], timss_and_gdp["Median Math Score (TIMSS Scale, 4th Grade)"])
```

Out[30]:
```
SpearmanrResult(correlation=0.6505076600204698, pvalue=8.243512060793219e-10)
```

In [31]:
```
stats.spearmanr(pirls_and_gdp["2015 [YR2015]"], pirls_and_gdp["Median Reading Score (PIRLS Scale, 4th Grade)"])
```

Out[31]:
```
SpearmanrResult(correlation=0.6764711507339786, pvalue=2.427725700137588e-10)
```

Οι τιμές επαληθεύουν το συμπέρασμα που προκύπτει από παρατήρηση των δεδομένων, ότι δηλαδή υπάρχει εμφανής συσχέτιση μεταξύ των δύο μεγεθών.

Παλινδρόμηση

Μελετώ μία ανεξάρτητη μεταβλητή (κατά κεφαλήν ΑΕΠ), η οποία φυσικά λαμβάνει συνεχείς τιμές, άρα πρώτα δοκιμάζω γραμμική παλινδρόμηση.

In [32]:
```
import statsmodels.api as sm
import statsmodels.formula.api as smf
```

Μετονομασία στηλών γιατί τη smf δεν λειτουργεί με κενά στα ονόματα:

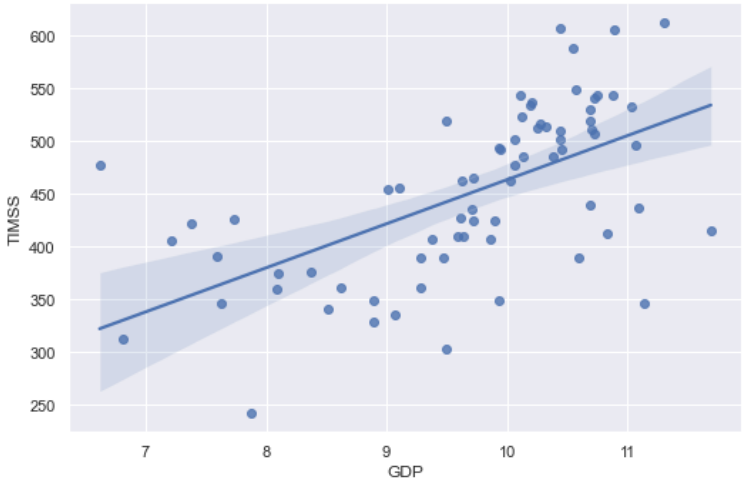
In [33]:
```
timss_and_gdp = timss_and_gdp.rename(columns = {"Median Math Score (TIMSS Scale, 4th Grade)": "TIMSS", "2015 [YR2015]": "GDP"})
```

In [34]:
```
timss_gdp_mod = smf.ols("TIMSS ~ GDP", data = timss_and_gdp)
timss_gdp_res = timss_gdp_mod.fit()
timss_gdp_res.params
```

Out[34]:
```
Intercept    46.117041
GDP          41.745974
dtype: float64
```

In [35]:
```
sns.lmplot(x = "GDP", y = "TIMSS", data = timss_and_gdp, aspect = 1.5)
```

Out[35]:
```
<seaborn.axisgrid.FacetGrid at 0x243208036d0>
```



In [36]:
```
timss_gdp_res.summary()
```

Out[36]:

OLS Regression Results

Dep. Variable:	TIMSS	**R-squared:**	0.352
Model:	OLS	**Adj. R-squared:**	0.342
Method:	Least Squares	**F-statistic:**	37.42
Date:	Tue, 19 Apr 2022	**Prob (F-statistic):**	5.07e-08
Time:	19:07:50	**Log-Likelihood:**	-396.25
No. Observations:	71	**AIC:**	796.5
Df Residuals:	69	**BIC:**	801.0
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	46.1170	66.734	0.691	0.492	-87.013	179.247
GDP	41.7460	6.824	6.117	0.000	28.132	55.360

Omnibus:	1.225	**Durbin-Watson:**	1.866
Prob(Omnibus):	0.542	**Jarque-Bera (JB):**	1.078
Skew:	-0.298	**Prob(JB):**	0.583
Kurtosis:	2.898	**Cond. No.**	85.3

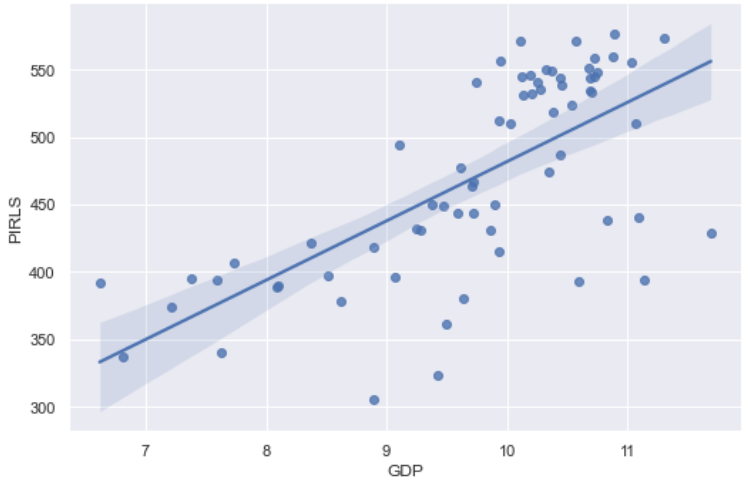
Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

In [37]:
```
pirls_and_gdp = pirls_and_gdp.rename(columns = {"Median Reading Score (PIRLS Scale, 4th Grade)": "PIRLS", "2015 [YR2015]": "GDP"})
pirls_gdp_mod = smf.ols("PIRLS ~ GDP", data = pirls_and_gdp)
pirls_gdp_res = pirls_gdp_mod.fit()
pirls_gdp_res.params
```

Out[37]:
```
Intercept    42.619127
GDP          43.912415
dtype: float64
```

In [38]:
```
sns.lmplot(x = "GDP", y = "PIRLS", data = pirls_and_gdp, aspect = 1.5)
```

Out[38]: <seaborn.axisgrid.FacetGrid at 0x243208b2df0>



In [39]:
```
pirls_gdp_res.summary()
```

Out[39]:

OLS Regression Results

Dep. Variable:	PIRLS	**R-squared:**	0.457
Model:	OLS	**Adj. R-squared:**	0.449
Method:	Least Squares	**F-statistic:**	55.61
Date:	Tue, 19 Apr 2022	**Prob (F-statistic):**	2.48e-10
Time:	19:08:03	**Log-Likelihood:**	-367.97
No. Observations:	68	**AIC:**	739.9
Df Residuals:	66	**BIC:**	744.4
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
Intercept	42.6191	57.790	0.737	0.463	-72.762	158.000
GDP	43.9124	5.889	7.457	0.000	32.155	55.669

Omnibus:	10.020	**Durbin-Watson:**	2.089
Prob(Omnibus):	0.007	**Jarque-Bera (JB):**	10.389
Skew:	-0.951	**Prob(JB):**	0.00555
Kurtosis:	3.226	**Cond. No.**	85.9

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Από τις τιμές R^2 που προκύπτουν φαίνεται πως η γραμμική παλινδρόμηση δεν εξηγεί πολύ μεγάλο ποσοστό των διακυμάνσεων.

E2: Χρόνια Εκπαίδευσης και Αποτελέσματα στα Τεστ

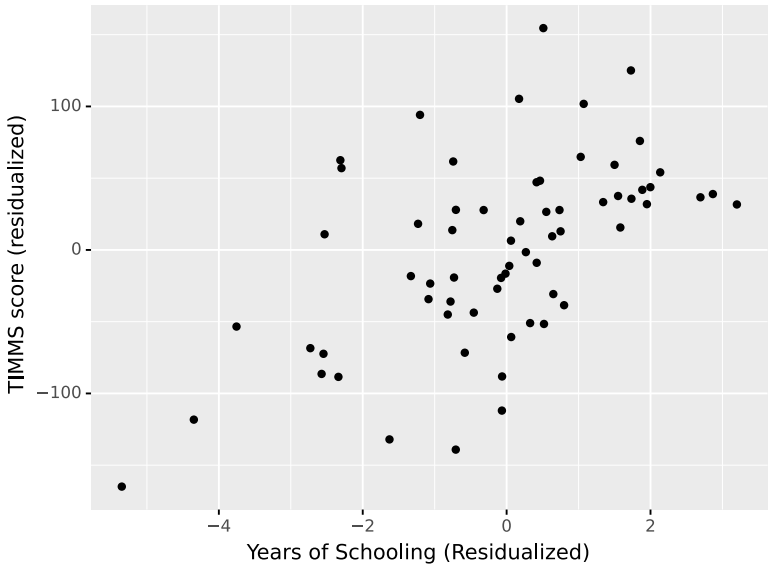
Θα διερευνήσετε πόσο επιδρούν τα χρόνια στο σχολείο στις επιδόσεις στα τεστ, λαμβάνοντας υπόψη το κατά κεφαλήν εισόδημα, όπως στο 4.1 και την εικόνα 6 της μελέτης. Για να το κάνετε αυτό, θα πάρετε τα υπόλοιπα (residuals) των μοντέλων που δημιουργήσατε στην E1. Τα υπόλοιπα περιέχουν ότι από τα αποτελέσματα δεν μπορεί να εξηγηθεί από το εισόδημα, οπότε θα τα χρησιμοποιήσετε για να δείτε πώς εξηγείται από τα χρόνια της εκπαίδευσης το μέρος των αποτελεσμάτων που δεν εξηγείται από το εισόδημα.

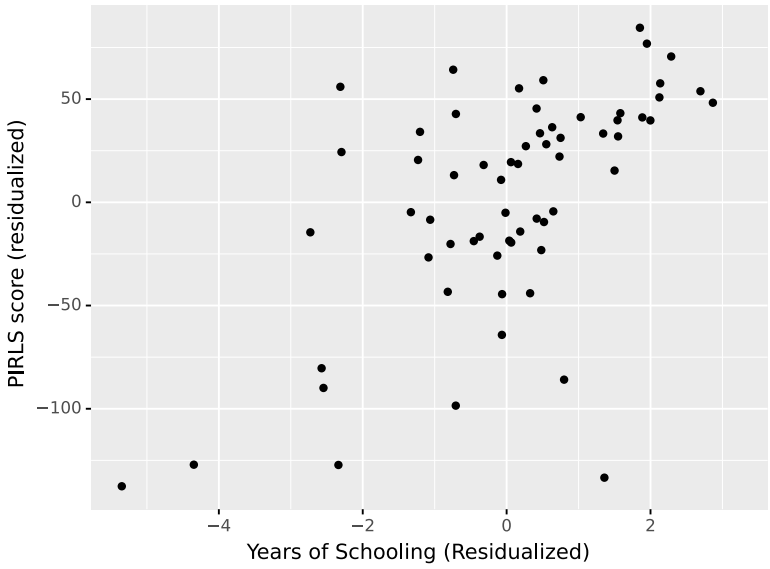
Έχετε λοιπόν ήδη τα υπόλοιπα από τα μοντέλα για τα TIMSS και PIRLS. Πλην όμως και τα χρόνια της εκπαίδευσης μπορεί να εξαρτώνται από το εισόδημα σε κάθε χώρα. Θα πρέπει να ορίσετε ένα μοντέλο με ανεξάρτητη μεταβλητή το λογαριθμισμένο κατά κεφαλή εισόδημα το 2015 και τα χρόνια εκπαίδευσης ως εξαρτημένη μεταβλητή. Δείξτε τα αποτελέσματα του μοντέλου και πάρτε τα υπόλοιπα. Αυτά τα υπόλοιπα αντιστοιχούν στα χρόνια της εκπαίδευσης που δεν μπορούν να εξηγηθούν από το εισόδημα.

Στη συνέχεια, κάντε μια παλινδρόμηση μεταξύ των υπολοίπων TIMMS και των υπολοίπων των ετών εκπαίδευσης και μια παλινδρόμηση μεταξύ των υπολοίπων PIRLS και των υπολοίπων των ετών εκπαίδευσης. Δείξτε τα αποτελέσματα και φτιάξτε διαγράμματα όπως τα παρακάτω.

Γιατί κάνουμε όλη αυτή την ιστορία με τα υπόλοιπα; Διότι είναι πιθανό ότι οι επιδόσεις των μαθητών και τα χρόνια που κάθονται στο σχολείο επηρεάζονται από το κατά κεφαλήν εισόδημα. Οπότε θέλουμε να τα εξετάσουμε χωρίς αυτήν την επιρροή.

Για να απαντήσετε την ερώτηση θα χρειαστείτε και το αρχείο `BL2013_MF1599_v2.2.dta` , το οποίο περιέχει τα δεδομένα των ετών εκπαίδευσης και προέρχεται από την εργασία των Barro, Robert J. and Jong-Wha Lee, A New Data Set of Educational Attainment in the World, 1950-2010, Journal of Development Economics, 2013, 104, 194-198. Θα χρησιμοποιήσετε τις τιμές για το 2010. Το αρχείο είναι στη μορφοποίηση του προγράμματος οικονομετρίας Stata, και μπορείτε να το διαβάσετε με το pandas με τη συνάρτηση `read_stata()` .





Οδηγίες Υποβολής

Θα πρέπει να υποβάλετε την εργασία σας με τη μορφή σημειωματαρίου (Jupyter notebook), το οποίο θα περιέχει το σύνολο του κώδικα και την ανάλυσή σας. Αυτό σημαίνει ότι το σημειωματάριο θα πρέπει να διαβάζεται και να γίνεται κατανοητό και ως κείμενο (αλλιώς η υποβολή θα ήταν απλώς ένα αρχείο Python). Ο σκοπός δεν είναι μόνο να δείξετε ότι ξέρετε να γράφετε κώδικα, αλλά να εξηγήσετε και να πείσετε τον αναγνώστη. θα πρέπει να υποβάλετε και όποια αρχεία δεδομένων χρησιμοποιείτε και να εξασφαλίσετε ότι το σημειωματάριο μπορεί να τρέξει χωρίς καμμία μετατροπή σε έναν άλλο υπολογιστή εκτός του δικού σας. Προσέξτε ιδιαιτέρως τα μονοπάτια ανάγνωσης των αρχείων, αυτά πρέπει να είναι σχετικά (relative paths) και όχι απόλυτα (absolute paths).

Κώδικας Τιμής

Συνειδητοποιείτε ότι αυτή είναι ατομική εργασία και θα πρέπει να εργαστείτε μόνοι σας. Μπορείτε βεβαίως να αναζητήσετε βοήθεια στο διαδίκτυο, αλλά αυτή θα πρέπει να αφορά τη χρήση των εργαλείων και ιδιωμάτων, δεν θα πρέπει να αναζητείτε την απάντηση στα ερωτήματα της εργασίας. Μπορείτε να συζητήσετε με άλλους που παρακολουθούν το μάθημα προκειμένου να λύσετε μεταξύ σας απορίες κατανόησης, αλλά όχι μεθόδους επίλυσης. Αναλογιστείτε ότι σκοπός του μαθήματος είναι να αποκομίσετε κάποιες γνώσεις, και όχι να ξοδέψετε απλώς τον χρόνο και τα χρήματά σας.